三高疾病風險預測：多模型比較研究
Risk Predicting Hypertension, Hyperglycemia, and Dyslipidemia A Multi-Model Comparative Study

國立臺北教育大學理學院資訊科學系
紀伯喬
Po-Chiao Chi

指導教授：許揚博士
Advisor: Yang Syu, Ph. D.

中華民國 115 年 7 月
July 2026

研究動機與目標

- 台灣 40 歲以上：

高血壓 38.3%、血脂異常 34.1%、高血糖 16.4%

- **4-7 成患者不自知**，三高常同時出現
- 2025 年健保署將成人健檢年齡歲下修至 30 歲
- 現有研究多為**單一疾病**、**單次健檢**預測
- 研究目標：
  1. 建立同時預測三高疾病風險的機器學習模型
  2. 驗證縱向變化量（Δ 特徵）的價值
  3. 提供可解釋的預測結果

研究架構

1. 原始健檢資料
2. 資料前處理
3. 特徵工程
4. 模型建立與評估

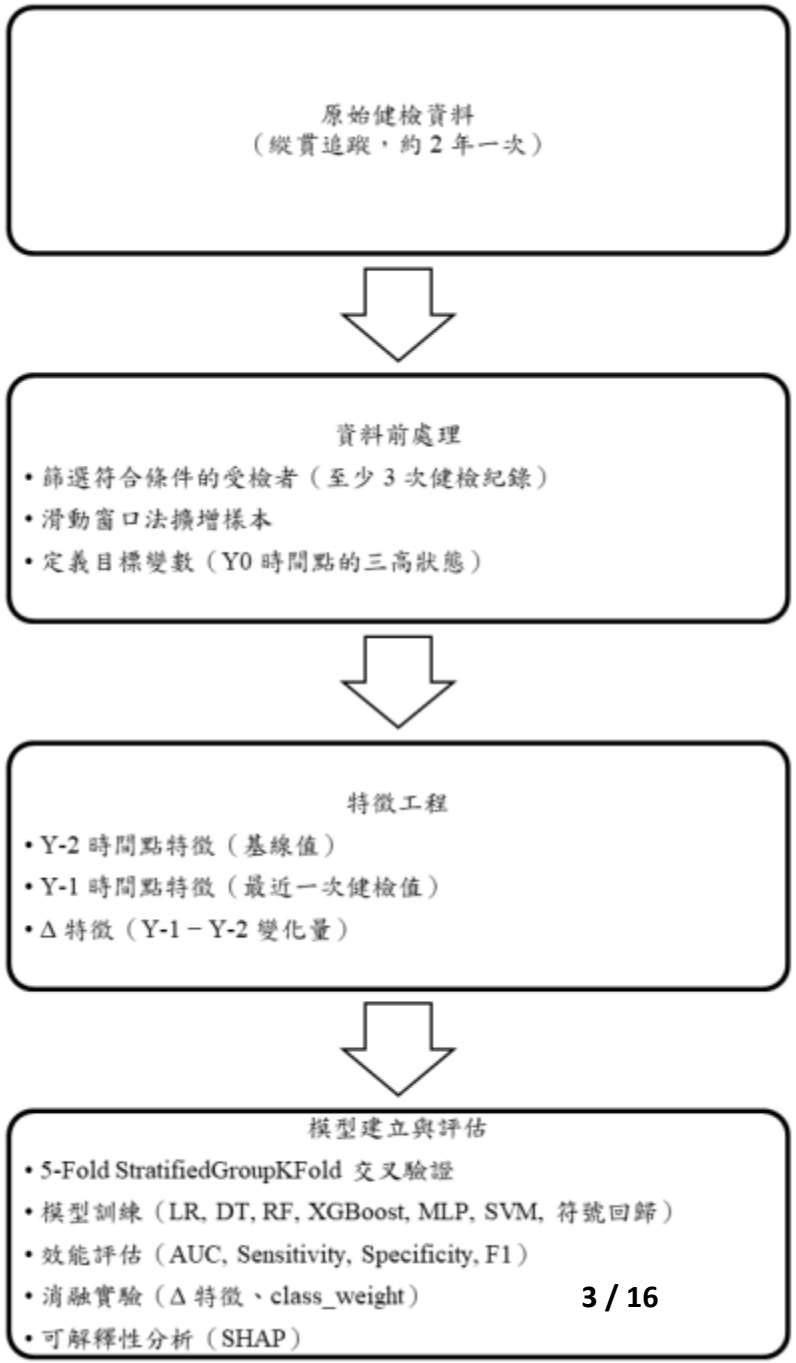

資料集概述

- 來源：Luo et al. (2024) Dryad 公開資料集，杭州 2010-2018
- 樣本篩選流程：
  - 原始群體 12,498 人（≥40 歲）
  - 排除：健檢 < 3 次（-2,618、資料缺失（-636、**已有三高（-3,125**
  - 原作者最終納入：6,119 人
  - 本研究再排除 < 3 次紀錄：**6,056 人**
  - **滑動窗口 → 13,514 筆**

- 盛行率：

高血壓 16.68%、高血糖 5.53%、高血脂 5.96%

- 時間結構圖：

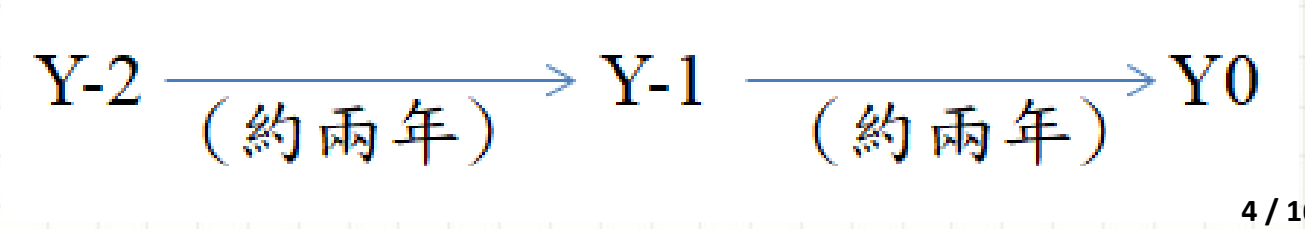

特徵工程

類別	特徵	數量
基本資訊	Sex, Age	2
Y-2 時間點	FBG, TC, Cr, UA, eGFR, BMI, SBP, DBP	8
Y-1 時間點	FBG, TC, Cr, UA, eGFR, BMI, SBP, DBP	8
Δ 變化量	ΔFBG, ΔTC, ΔCr, ΔUA, ΔeGFR, ΔBMI, ΔSBP, ΔDBP	8
合計		**26**

- Δ = Y-1 − Y-2（反映趨勢變化）
- 範例：舒張壓 125→140 (風險上升)

模型選擇

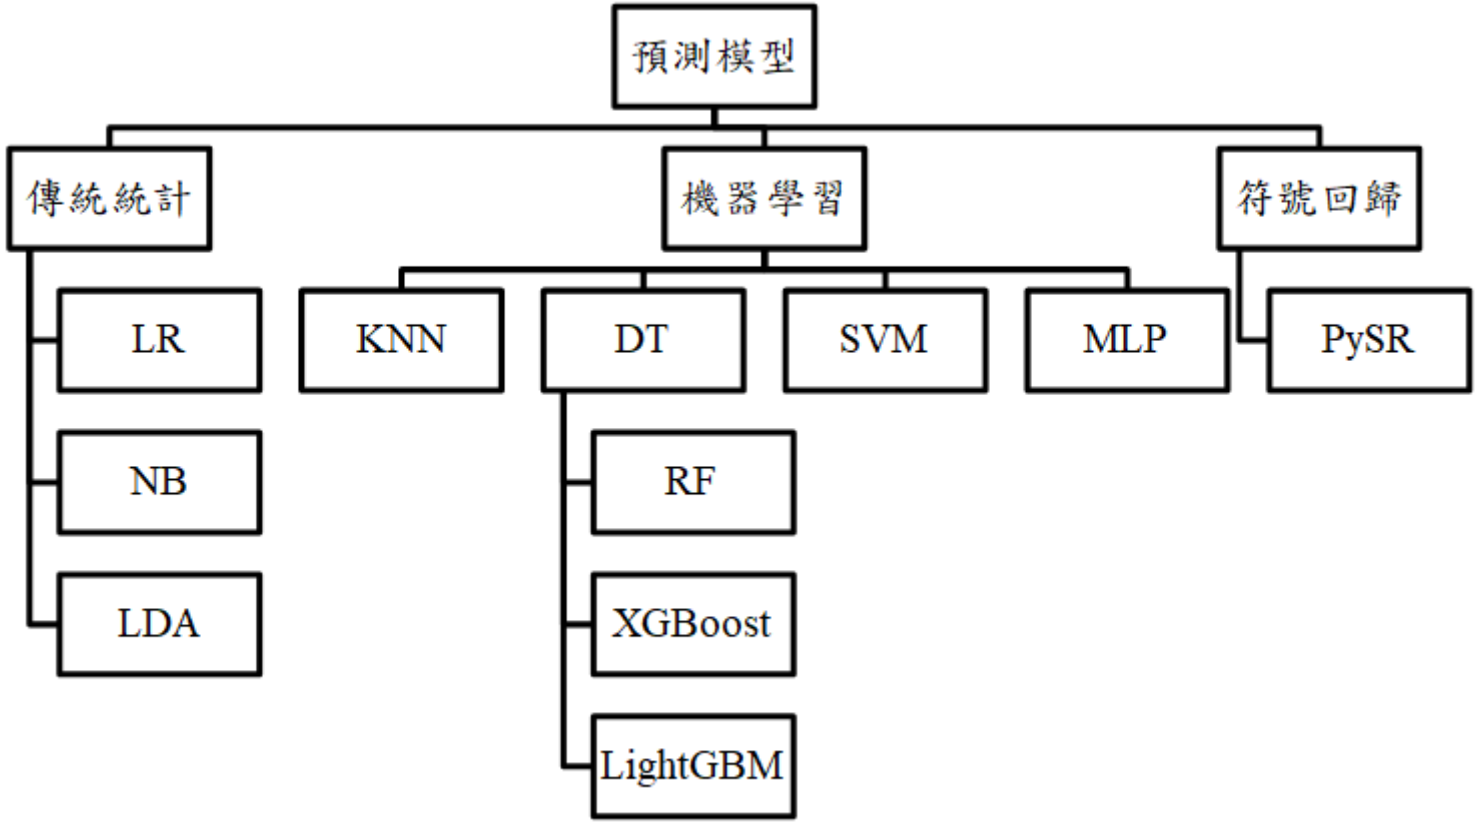
預測模型
傳統統計
機器學習
符號回歸
LR
NB
LDA
KNN
DT
SVM
MLP
PySR
RF
XGBoost
LightGBM

實驗設計

- 驗證：StratifiedGroupKFold 5-fold CV
- 主要指標：AUC-ROC

實驗	想回答的問題
一、模型比較（10 模型 × 3 疾病）	哪種模型兼顧準確性與穩定性？
二、Δ 特徵消融（Full vs No-Δ / Y-1+Δ vs Y-1）	縱向變化量是否提升預測力？
三、特徵選擇（Top 1/2/5/10/15/20/26）	最少幾個特徵即可有效篩檢？
四、健檢次數（1/2/3/4 次）	多次健檢是否改善預測？
五、類別不平衡（5 種方法比較）	陽性樣本稀少時如何處理？
六、MTL vs STL	同時預測三高是否更有效率？

實驗結果：模型比較

模型	高血壓	高血糖	高血脂
LR	0.721	**0.938**	**0.867**
NB	0.709	0.917	0.847
LDA	0.720	0.936	0.867
KNN	0.630	0.782	0.673
DT	0.658	0.835	0.744
RF	**0.743**	0.932	0.859
XGB	0.738	0.930	0.857
LGBM	0.730	0.926	0.852
SVM	0.726	0.919	0.845
MLP	0.703	0.919	0.742

實驗結果：Δ 特徵的價值

- SHAP 分析：
  - Δ 在 Top 10 佔比：
    - 高血壓 30% / 高血糖 40% / 高血脂 **50%**
  - **ΔeGFR 出現在全部三個疾病 →**
    - 腎功能變化是共通風險信號
- 消融實驗：
  - Full 26 vs No-Δ 18：AUC 差異 < 0.1%
  - Y-1+Δ vs Y-1 Only：**+1.5~2.3%**
- **Δ 三重角色**：預測冗餘 / 縱向替代 / 可解釋性

實驗結果：特徵選擇

特徵數	高血壓	高血糖	高血脂
1	0.686	0.920	0.805
2	**0.743**	**0.932**	**0.858**
5	0.752	0.933	0.868
10	0.754	0.933	0.868
26 (全部)	0.754	0.932	0.867

- Top 2 = 同一指標在兩個時間點（如 SBP_Y-2 + SBP_Y-1）
- Top 5 → 26：AUC 改善 < 0.5%
- 臨床意義：2-5 個指標即可低成本篩檢

實驗結果：健檢次數

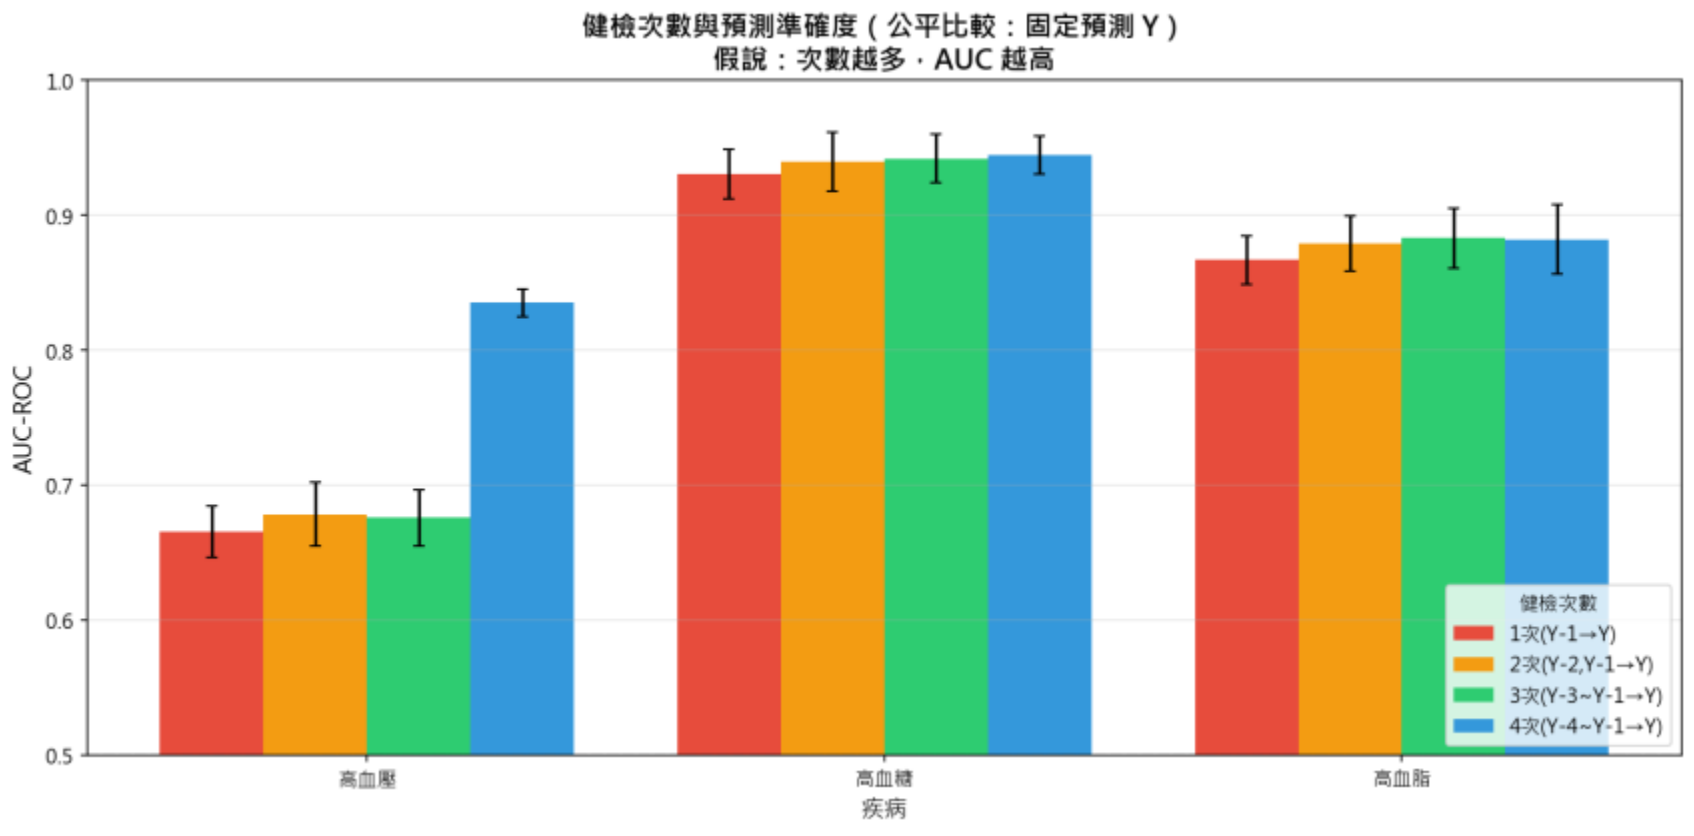
健檢次數與預測準確度（公平比較：固定預測 Y）
假說：次數越多，AUC 越高
AUC-ROC
1.0
0.9
0.8
0.7
0.6
0.5
高血壓
高血糖
高血脂
疾病
健檢次數
1次(Y-1→Y)
2次(Y-2,Y-1→Y)
3次(Y-3~Y-1→Y)
4次(Y-4~Y-1→Y)

實驗結果：類別不平衡處理

疾病	指標	無處理	class_weight	SMOTE	ADASYN	欠採樣
高血壓	AUC	0.719	0.720	0.719	0.719	0.719
	Sens	**0.041**	**0.698**	0.698	0.696	0.699
高血糖	AUC	0.937	0.937	0.937	0.936	0.937
	Sens	**0.335**	**0.861**	0.852	0.877	0.864
高血脂	AUC	0.863	0.864	0.863	0.863	0.862
	Sens	**0.135**	**0.791**	0.785	0.794	0.790

- AUC 差異 < 0.2%（各方法一樣）
- Sensitivity (Recall) 提升 50-70 百分點
- class_weight='balanced' 最簡單有效

實驗結果：MTL vs STL

疾病	指標	MTL	STL	差異
高血壓	AUC	0.733	0.742	-0.9%
	Sens (Recall)	0.797	0.798	-0.001
	Spec	0.564	0.581	-0.017
高血糖	AUC	0.932	0.933	-0.1%
	Sens	0.860	0.874	-0.014
	Spec	0.870	0.870	0.000
高血脂	AUC	0.868	0.869	-0.1%
	Sens	0.828	0.819	**+0.009**
	Spec	0.757	0.765	-0.008

延伸研究：符號回歸

疾病	公式	AUC	穩定性
高血壓	0.130 × exp(舒張壓_Y-2)	0.745	2/5 folds
高血糖	**0.114 × 空腹血糖_Y-1**	**0.943**	**5/5 folds**
高血脂	0.043 × exp(總膽固醇_Y-2)	0.801	2/5 folds

- AUC 0.943 > XGBoost 0.930 > LR 0.938
- 1 特徵 × 1 乘法 → 零成本部署
- 5/5 folds 穩定（AUC 0.918 ± 0.016）

研究貢獻與限制

- 學術貢獻：
  - 首次將 Δ 特徵應用於**同時**三高預測
  - 涵蓋範圍較廣的模型比較：10 模型 × 6 組實驗
  - 發現 LR 穩定性優勢 + HG 線性公式（0.943 AUC）
  - 釐清 Δ 的三重角色（冗餘 / 替代 / 可解釋性）
- 應用價值：
  - Top 2 特徵即可篩檢 → 低成本部署
  - 符號回歸公式 → 無需 ML 基礎設施
  - 定期健檢證據 → 支持公衛政策
- 限制：
  - 缺乏生活型態資料（飲食、運動、吸菸）
  - 無外部驗證資料集
  - 用藥資訊缺失 → 標籤定義不精確

未來方向

- 資料擴展：
  - 加入飲食/生活型態特徵（DGA 2025）— 可介入風險因子
  - 納入用藥紀錄 → 區分「控制中」vs「真陽性」
  - 與其他健檢中心合作 → 外部驗證
- 方法改進：
  - 累積 5+ 次健檢 → 深度時序模型（LSTM / Transformer）
  - 改進 MTL：動態權重調整、梯度平衡
  - 個體層級解釋：反事實分析 → 個人化建議
- 疾病擴展：
  - 將 Δ 特徵框架推廣至心血管疾病、腎臟病、代謝症候群