

三高疾病風險預測：經驗性比較研究

An Empirical Study on Risk Prediction of Hypertension, Hyperglycemia, and Dyslipidemia

國立臺北教育大學理學院資訊科學系

紀伯喬 Po-Chiao Chi

指導教授：許揚博士

Advisor: Yang Syu, Ph. D.

中華民國 115 年 5 月

May 2026

研究動機與目標

- 台灣 40 歲以上：
高血壓 38.3%、高血脂 34.1%、高血糖 16.4%
- **4-7 成患者不自知**，三高常同時出現
- 2025 年健保署將成人健檢年齡下修至 **30 歲**
- 現有研究多為**單一疾病、單次健檢**預測
- 研究目標：
 1. 建立同時預測三高疾病風險的機器學習模型
 2. 驗證縱向變化量 (Δ 特徵) 的價值
 3. 提供可解釋的預測結果

文獻定位 – 表 2-1


研究	預測目標	資料來源	樣本數	最佳模型	AUC	Δ 特徵	設計
Ye et al.[11]	高血壓	EHR(美國)	823,627	XGBoost	0.917	無	縱向
Alaa et al.[12]	心血管 疾病	UK Biobank	423,604	AutoProgn osis	0.774	無	縱向
Dinh et al.[13]	糖尿病	NHANES (註 1)	21,131	XGBoost	0.862	無	橫斷面
Kanegae et al.[9]	高血壓	日本職場 健檢	18,258	XGBoost	0.881	有	縱向
Hung et al.[14]	隱匿性 高血壓	台灣醫院	1,386	RF	0.851	無	橫斷面
Liu et al.[15]	糖尿病	台中榮總 EHR	6,687	XGBoost	0.930	無	縱向
Wang et al.[16]	高血壓	台灣美兆	207,488	XGBoost	0.889	無	縱向
Yang et al.[10]	前驅 糖尿病	台灣美兆	6,247	XGBoost	—	有	縱向
Majcherek et al.[17]	糖尿病	BRFSS (美國)	253,680	Extra Trees	0.99 (註 2)	無	橫斷面
本研究	三高 (同時)	杭州社區 調查	6,056	LR / RF	0.721– 0.938	有	縱向

文獻定位 – 表 2-2

研究	模型方 法數量	度量值 數量	目標 疾病	特徵相關			類別 平衡	解釋性 分析
				Δ 特徵	次數	特徵 數量		
Ye [11]	1	4	HTN					
Alaa [12]	9	4	CVD					
Dinh [13]	5	6	DM					
Kanegae [9]	3	3	HTN	✓				
Hung [14]	4	7	HTN					
Liu [15]	3	5	DM					
Wang [16]	3	4	HTN		✓			
Yang [10]	5	8	DM	✓				✓
Majcherek [17]	18	6	DM					✓
Tsai [27]	6	6	多疾病					
本研究	10	4	三高	✓	✓	✓	✓	✓


研究架構 -圖 4-1

1. 原始健檢資料
2. 資料前處理
3. 特徵工程
4. 模型建立與評估



資料集概述 – 圖 4-2

- 來源：Luo et al. (2023) Dryad 公開資料集，杭州 2010-2018
- 樣本篩選流程：
 - 原始群體 12,498 人 (≥ 40 歲)
 - 排除：健檢 < 3 次 (-2,618、資料缺失 (-636、已有三高 (-3,125
 - 原作者最終納入：6,119 人
 - 本研究再排除 < 3 次紀錄：**6,056 人**
 - 滑動窗口 $\rightarrow$ **13,514 筆**
- 盛行率：高血壓 16.68%、高血糖 5.53%、高血脂 5.96%
- 時間結構圖：




特徵工程 – 表 4-2

類別	特徵	數量
基本資訊	Sex, Age	2
Y-2 時間點	FBG, TC, Cr, UA, eGFR, BMI, SBP, DBP	8
Y-1 時間點	FBG, TC, Cr, UA, eGFR, BMI, SBP, DBP	8
Δ 變化量	Δ FBG, Δ TC, Δ Cr, Δ UA, Δ eGFR, Δ BMI, Δ SBP, Δ DBP	8
合計		26

- $\Delta = Y-1 - Y-2$ (反映趨勢變化)
- 範例：收縮壓 125→140 (風險上升)

模型選擇 – 圖 5-1



實驗設計

- 驗證：StratifiedGroupKFold 5-fold CV
- 主要指標：AUC-ROC

實驗	想回答的問題
一、模型比較（10 模型 × 3 疾病）	哪種模型兼顧準確性與穩定性？
二、 Δ 特徵消融（Full vs No- Δ / Y-1+ Δ vs Y-1）	縱向變化量是否提升預測力？
三、特徵選擇（Top 1/2/5/10/15/20/26）	最少幾個特徵即可有效篩檢？
四、類別不平衡（5 種方法比較）	陽性樣本稀少時如何處理？
五、健檢次數預測力（1/2/3/4 次）	多次健檢是否改善預測？
六、各時間點獨立預測力（T1, T2, T3, T4→T5）	時間越近準確度越高？
七、MTL vs STL	同時預測三高是否更有效率？

實驗結果：模型比較

模型	高血壓	高血糖	高血脂
LR	0.721	0.938 (1)	0.867 (1)
NB	0.709	0.917	0.847
LDA	0.720	0.936 (2)	0.867 (1)
KNN	0.630	0.782	0.673
DT	0.658	0.835	0.744
RF	0.743 (1)	0.932 (3)	0.859 (3)
XGB	0.738 (2)	0.930	0.857
LGBM	0.730 (3)	0.926	0.852
SVM	0.726	0.919	0.845
MLP	0.703	0.919	0.742

過擬合分析

模型類別	Train AUC	Test AUC	Gap
傳統統計 (LR/NB/LDA)	0.73-0.94	0.71-0.94	≤ 0.01
樹模型 (RF/XGB/LGBM)	0.97-1.00	0.73-0.93	0.06-0.25
神經網路 (MLP)	0.72-0.94	0.70-0.92	≤ 0.02

簡單模型 (LR) 幾乎無過擬合

樹模型過擬合明顯，但測試集仍有競爭力

→ 這也解釋為什麼 LR 在測試集上穩定優異


實驗結果： Δ 特徵的價值

實驗組	特徵數	高血壓	高血糖	高血脂	揭露
Full (Y-2+Y-1+ Δ)	26	0.721	0.938	0.867	基準
No- Δ (Y-2+Y-1)	18	0.721	0.938	0.867	預測冗餘
Y-1+ Δ	18	0.721	0.938	0.867	縱向替代
Y-1-Only	10	0.698	0.923	0.846	
Y-2-Only	10	0.698	0.889	0.814	
Δ -Only	10	0.593	0.668	0.636	不可單獨用

實驗結果：特徵選擇


特徵數	高血壓	高血糖	高血脂
1	0.686	0.920	0.805
2	0.743	0.932	0.858
5	0.752	0.933	0.868
10	0.754	0.933	0.868
26 (全部)	0.754	0.932	0.867

SHAP 特徵重要性 (滑動視窗資料)




實驗結果：健檢次數

健檢次數與預測準確度（公平比較：固定預測 Y）
假說：次數越多，AUC 越高



實驗結果：健檢時間點比較

各時間點獨立預測力 (LR, n=2,526, 預測 T5)



- 對象：2,526 名健檢者，各時間點獨立預測 T5
- 高血糖/高血脂：T4 最強，越遠越弱 → 符合直覺
- 高血壓：T1 最強，高出 T2-T4 達 0.12-0.16 → 反直覺

假說

為什麼高血壓 T1 最強？

推測：入組篩選 + 降壓藥干預

- T1 為世代研究入組時間點，排除已確診高血壓
- T1 血壓反映「未經藥物干預的自然狀態」
- T2-T4 期間部分受試者可能開始服降壓藥 → 血壓被藥效壓低

為什麼高血脂沒有同樣模式？

比較	高血壓	高血脂
藥效速度	快（數天~數週）	慢（4-6 週）
量測值波動	大（受藥物即時操控）	小（被平均化）

實驗結果：類別不平衡處理

疾病	指標	無處理	class_weight	SMOTE	ADASYN	欠採樣
高血壓	AUC	0.719	0.720	0.719	0.719	0.719
	Sens	0.041	0.698	0.698	0.696	0.699
高血糖	AUC	0.937	0.937	0.937	0.936	0.937
	Sens	0.335	0.861	0.852	0.877	0.864
高血脂	AUC	0.863	0.864	0.863	0.863	0.862
	Sens	0.135	0.791	0.785	0.794	0.790

- AUC 差異 < 0.2% (各方法一樣)
- Sensitivity (Recall) 提升 50-70 百分點
- class_weight='balanced' 最簡單有效

實驗結果：MTL vs STL

疾病	指標	MTL	STL	差異
高血壓	AUC	0.733	0.742	-0.9%
	Sens (Recall)	0.797	0.798	-0.001
	Specificity	0.564	0.581	-0.017
高血糖	AUC	0.932	0.933	-0.1%
	Sensitivity	0.860	0.874	-0.014
	Specificity	0.870	0.870	0.000
高血脂	AUC	0.868	0.869	-0.1%
	Sensitivity	0.828	0.819	+0.009
	Specificity	0.757	0.765	-0.008

延伸研究：符號回歸

疾病	公式	AUC	穩定性
高血壓	$0.130 \times \exp(\text{舒張壓_Y-2})$	0.745	2/5 folds
高血糖	$0.114 \times \text{空腹血糖_Y-1}$	0.943	5/5 folds
高血脂	$0.043 \times \exp(\text{總膽固醇_Y-2})$	0.801	2/5 folds

- AUC 0.943 > XGBoost 0.930 > LR 0.938
- 1 特徵 × 1 乘法 → 零成本部署
- 5/5 folds 穩定 (AUC 0.918 ± 0.016)

個人健檢 demo

輸入 (2 次健檢 + Δ)

- 2025/9 + 2026/3 的 26 個特徵
- 性別、年齡、SBP、DBP、FBG、TC、Cr、UA、eGFR、BMI 等

預測結果 (LR 模型)

疾病	患病機率	判定
高血壓	37.2%	低風險 (三項中最高)
高血糖	2.7%	非常低
高血脂	12.6%	低風險

研究貢獻與限制

學術貢獻

- 首次將 Δ 特徵應用於同時三高預測
- 涵蓋範圍較廣的模型比較：10 模型 $\times$ 7 組實驗
- 發現 LR 穩定性優勢 + 高血糖線性公式 (AUC 0.943)
- 釐清 Δ 的三重角色 (冗餘 / 替代 / 可解釋性)

應用價值

- Top 2 特徵即可篩檢 $\rightarrow$ 低成本部署
- 符號回歸公式 $\rightarrow$ 無需 ML 基礎設施
- 定期健檢證據 $\rightarrow$ 支持公衛政策

限制

- 缺乏生活型態資料 (飲食、運動、吸菸)
- 無外部驗證資料集 (外部效度受限)
- 未做校準度分析 (calibration plot / Hosmer-Lemeshow)
- 用藥資訊缺失 $\rightarrow$ 標籤定義不精確

美國膳食指南 2025-2030

三大行動建議	與三高的關聯
添加糖：理想攝取量 = 0	TC↑、HDL↓、FBG 波動
蛋白質：1.2–1.6 g/kg（過去 RDA 0.8）	取代精製碳水、穩定血糖
減少精製碳水（白麵包、糕點）	胰島素阻抗 → 三高共病

首度明確反對：超加工食品、非營養性甜味劑（阿斯巴甜、蔗糖素）

對本研究的意涵

- 本研究 26 個特徵皆為**生理指標**（不可即時改變）
- DGA 提示的飲食變項是**可介入**的上游因子
- 未來若能整合飲食頻率資料，預期可提升預測力 + 提供可操作建議

未來方向

- 資料擴展：
 - 加入飲食/生活型態特徵 (DGA 2025) — 可介入風險因子
 - 納入用藥紀錄 → 區分「控制中」vs「真陽性」
 - 與其他健檢中心合作 → 外部驗證
- 方法改進：
 - 累積 5+ 次健檢 → 深度時序模型 (LSTM / Transformer)
 - 改進 MTL：動態權重調整、梯度平衡
 - 個體層級解釋：反事實分析 → 個人化建議
- 疾病擴展：
 - 將 Δ 特徵框架推廣至心血管疾病、腎臟病、代謝症候群